Análisis Bayesiano de la Industria del Anime: Calidad Productiva y Fidelización de Audiencia

Propuesta de Proyecto — Métodos Bayesianos

Nicolas Sanchez Adrian Godoy Cristobal Fuentes Vicente Olivares

11 de mayo de 2026

1. Introducción

La industria del anime es un sector de gran éxito mundial, con una audiencia global y formas de consumo muy particulares. Por ello, entender qué hace que un anime sea exitoso es una pregunta clave tanto para los fans como para la propia industria.

En este proyecto, consideramos que el "éxito" de un anime se puede medir de dos formas: por la calidad que percibe el público (las notas que le dan) y por la fidelidad de la audiencia (la proporción de espectadores que lo marcan como favorito). Aunque un anime con buena nota suele tener muchos fans, esto no siempre es así: hay series muy populares que pocos marcan como favoritas, y series de nicho con fans muy apasionados. Esta diferencia nos motiva a estudiar ambas medidas por separado.

Para esto, planteamos dos grandes preguntas de investigación: una enfocada en quién hace el anime (los estudios) y otra en quién lo consume (la audiencia). Las responderemos usando estadística bayesiana. En este documento detallamos el contexto, explicamos qué datos usamos, cómo los limpiamos y presentamos un análisis inicial que sirve de base para nuestro trabajo posterior.

2. Contexto y Preguntas de Investigación

2.1. Contexto del fenómeno

El mercado global del anime es gigante; generó cerca de 25 mil millones de dólares en 2024 (2024--2025), impulsado en gran parte por las plataformas de streaming. En este negocio, decidir qué producir depende mucho de estudiar qué le gusta a la gente y qué tan fieles son a las series.

Ante esto, surgen dos dudas principales. Primero, desde la **producción**: hay muchos estudios de animación que se han especializado en adaptar mangas, novelas o crear historias originales. Nos preguntamos si esto se nota en la calidad final; es decir, ¿hay estudios que son mejores produciendo ciertas cosas? Segundo, desde el **consumo**: sabemos que un anime puede ser muy visto, pero no necesariamente amado. Nos interesa saber qué géneros narrativos logran atrapar más el "corazón" del público, independientemente de que la serie sea muy conocida o no.

Para responder a estas preguntas nos enfrentamos a un reto estadístico: tenemos datos de estudios que han hecho cientos de animes, pero otros que han hecho muy pocos. Esto dificulta usar métodos estadísticos tradicionales. Sin embargo, los métodos bayesianos jerárquicos permiten tomar informa-

ción prestada entre categorías (lo que se conoce como *partial pooling*), dándonos estimaciones mucho más robustas y manejables cuando hay pocos datos.

2.2. Preguntas de investigación

A partir del contexto descrito, este proyecto se estructura en torno a dos preguntas de investigación complementarias. La primera adopta una perspectiva orientada al lado de la producción y se centra en la calidad evaluativa; la segunda adopta una perspectiva orientada al lado del consumo y se centra en la fidelización profunda.

2.2.1. Pregunta 1: Lado de la producción

¿Qué tanta diferencia de calidad (según la nota en MyAnimeList) existe entre los distintos estudios de animación cuando adaptan diferentes tipos de material (manga, novela, videojuego, etc.)?

En el mundo del anime, los estudios suelen especializarse. Queremos saber si esta especialización realmente se nota en la calidad del producto final o si depende más del material original. Trataremos de ver si hay estudios que destaquen sistemáticamente, usando un modelo bayesiano que nos permita incluir incluso a aquellos estudios que han producido muy pocas series, compensando su falta de datos con el promedio general.

2.2.2. Pregunta 2: Lado del consumo

¿Qué géneros logran una mayor fidelidad (proporción de favoritos sobre el total de espectadores), independientemente de la popularidad general de la serie?

Sabemos que una serie muy popular no siempre genera fans "leales". Un anime puede ser visto por muchos pero pasar al olvido, mientras que otro menos conocido puede convertirse en obra de culto. Queremos averiguar qué géneros logran esta conexión emocional más fuerte. Usaremos un modelo estadístico que maneje bien el hecho de que algunas tasas de fidelidad son extremadamente bajas, controlando por el año de estreno del anime.

3. Datos

3.1. Procedencia y muestra

Usamos datos de MyAnimeList (MAL) (MyAnimeList LLC, 2025), una plataforma extensiva donde los usuarios registran, califican y discuten animes. MAL es una fuente muy rica porque mezcla datos oficiales de producción (estudio, género, fechas) con datos reales de consumo (cuánta gente ve la serie, qué notas le pone y cuántos la marcan como favorita).

Trabajamos con el dataset *MyAnimeList 2025* de Kaggle (Apriansyah 2025), que contiene casi 20.000 animes desde la década de 1960 hasta 2025. Luego de limpiar la base, nos quedamos con una selección de aproximadamente **4.500 series de televisión** sobre las cuales haremos el estudio.

3.2. Definición de variables

La Tabla 1 resume las variables principales que usamos. Hemos quitado del listado a aquellas que no aportan al análisis estadístico (como descripciones largas o URLs).

Tabla 1: Variables utilizadas en el análisis.

Variable	Descripción
Score	Nota del 0 al 10, de acuerdo al promedio de usuarios en MAL.
Favorites	Número de personas que marcaron la serie como favorita.
Members	Número total de personas que tienen la serie en su lista.
Studios	Estudio(s) encargado(s) de la animación.
Source	Origen de la historia (manga, novela, original, etc.).
Genres	Géneros narrativos de la serie.
Premiered	Fecha de estreno, de donde sacamos el año.
Type	Formato (TV, película, OVA). Nos quedaremos solo con TV.
Rating	Clasificación por edad. Lo usamos para dejar fuera series para adultos ('Hentai').
Episodes	Cuántos episodios tiene.

También creamos tres variables nuevas: la **tasa de favoritos** (Favorites dividido por Members), el **año de estreno** en formato número, y agrupamos **Source** (el origen) en cinco grandes grupos: *Original*, *Manga*, *Novel*, *Game/VN* y *Other*, para que el análisis sea más limpio.

3.3. Limpieza y reducción de la muestra

Para filtrar los datos, aplicamos los siguientes pasos (ver resumen en la Tabla 2):

1. **Quitar estudios mal registrados:** Eliminamos unos 4.400 casos donde el estudio aparecía como "add some" (un error del raspado web, que tomó el botón de "añadir estudio" de MAL como si fuera un nombre).
2. **Excluir contenido para adultos (Hentai):** Quitamos 1.557 registros porque sus dinámicas de consumo y notas son demasiado distintas al anime normal, lo que ensuciaría los resultados.
3. **Dejar solo series de TV:** Las películas u OVAs se consumen y califican de formas distintas, y muchas no tienen el año de estreno bien registrado en los datos.
4. **Datos completos:** Dejamos solo los animes que tuvieran las variables clave enteras (Score, Members, Favorites y año). Si una serie tiene más de un estudio, nos quedamos con el primero que aparece, que suele ser el principal.
5. **Mínimo de audiencia:** Para analizar la fidelidad (Pregunta 2), exigimos que la serie tenga al menos 1.000 *Members*. Las series con menos público dan tasas de favoritismo muy inestables que solo meten "ruido" al modelo.

4. Análisis Descriptivo

4.1. Visión general de los datos

Tabla 2: Resumen del filtrado de datos.

Paso	N animes
Dataset original (MyAnimeList, nov. 2025)	19,931
Tras excluir registros sin información básica	13,716

Paso	N animes
Restringido a Tipo = TV	5,509
Con Score, Members, Favorites y Año disponibles	4,589
Subconjunto Pregunta 2 (Members $\geq$ 1000)	4,487

Nuestra base principal se quedó con 4,589 animes, y un poco menos para el análisis de fidelidad, debido al filtro de 1.000 usuarios mínimos.

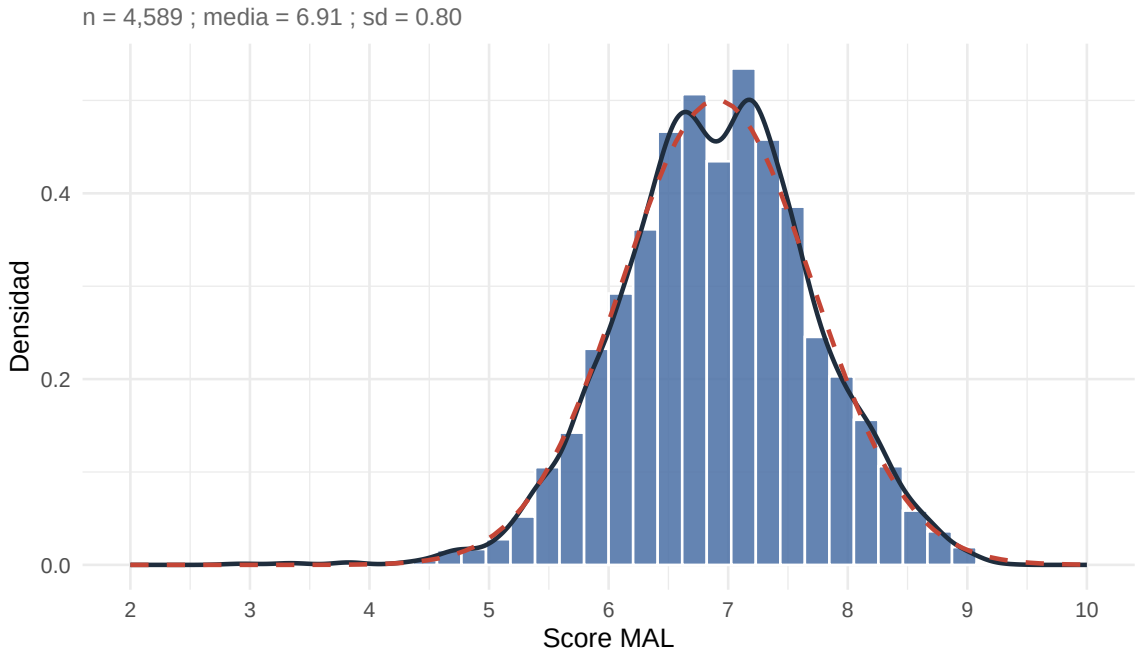

Figura 1: Distribución de las notas (Score). La línea continua es la curva real; la discontinua, una curva normal normal teórica.

La distribución del Score (Figura 1) es muy simétrica. La gran mayoría de las notas caen entre 4.5 y 8.5. Dado que estas notas ya son promedios de lo que votan miles de usuarios, siguen una curva muy cercana a lo que en estadística se llama *distribución normal*. Esto nos facilita crear el modelo matemático para la Pregunta 1.

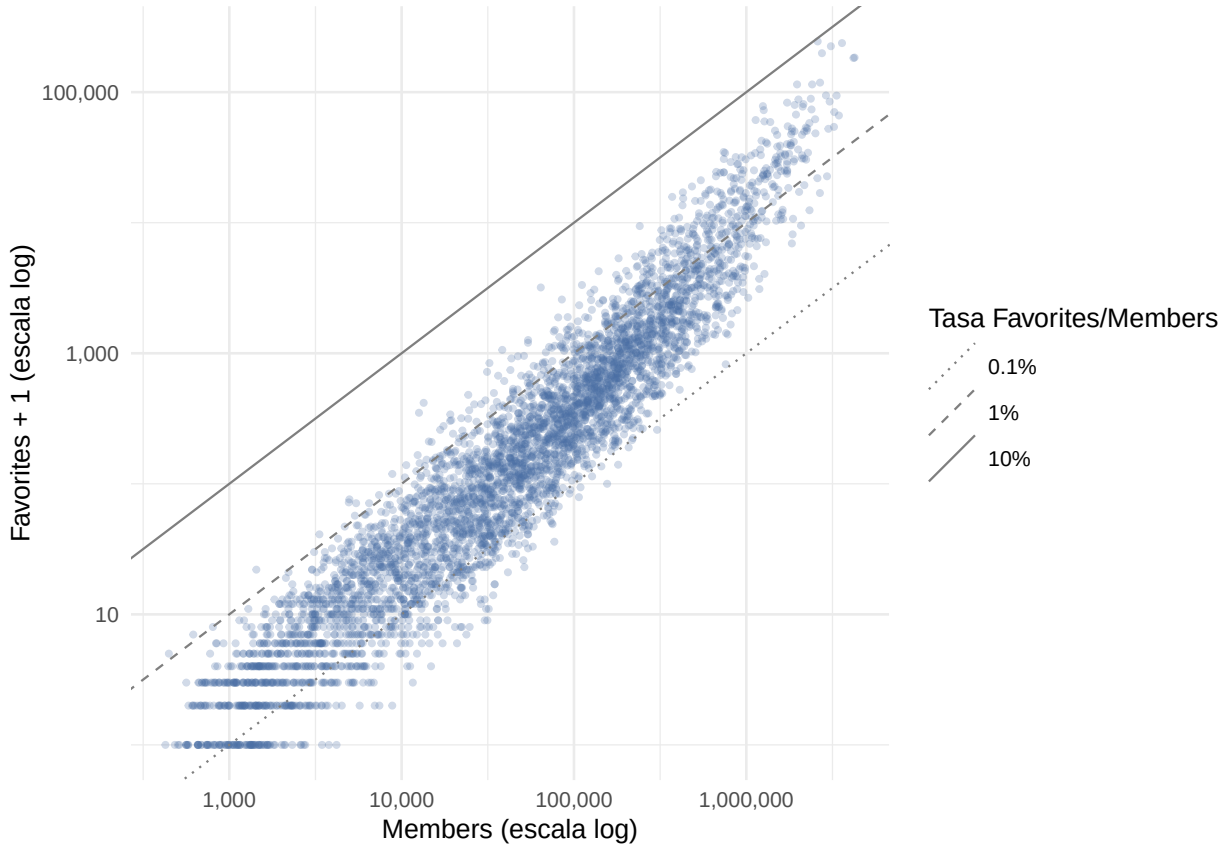

Figura 2: Relación entre tamaño de la audiencia (Members) y número de favoritos absolutos (Favorites + 1, escala log10). Las líneas grises de referencia corresponden a tasas constantes de favoritos del 0.1 %, 1 % y 10 %.

La Figura 2 nos muestra tres cosas importantes para la Pregunta 2. Primero, la gran diferencia en público que tienen las series (desde decenas a millones). Segundo, que lo normal es que solo entre el 0.1 % y el 1 % de los espectadores guarden la serie como favorita. Tercero, que los puntos están muy dispersos y no forman una línea perfecta, lo cual justifica el uso de un modelo estadístico un poco más flexible (Beta-Binomial) para manejar esta amplia variación.

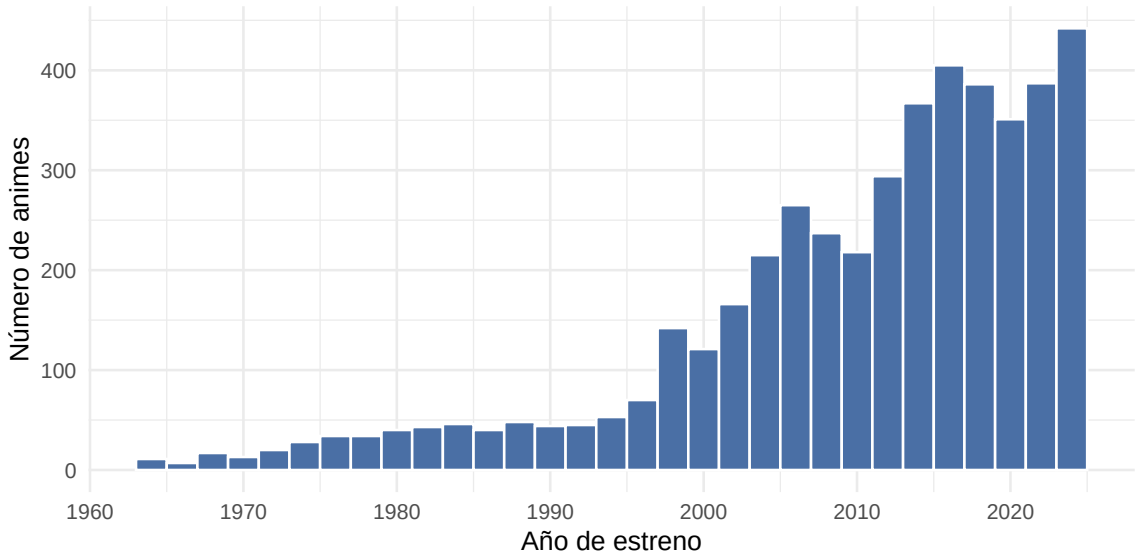

Figura 3: Distribución de los animes incluidos en la muestra, según su año de estreno.

El subconjunto cubre obras desde los 60s, notándose claramente el "boom" del anime a partir del 2000. Como las series más recientes han tenido menos tiempo para juntar fans o reseñas, usaremos el año de estreno en nuestros modelos para evitar que esto afecte los resultados.

4.2. Lado de la producción: estudios y material original

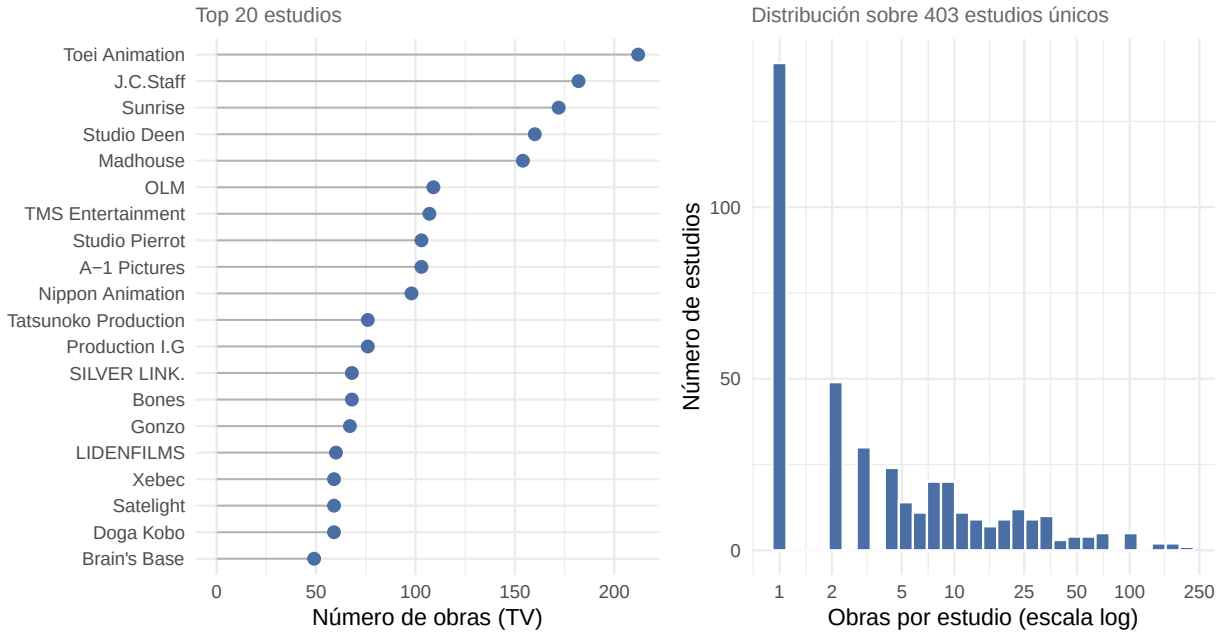

Figura 4: Distribución del número de obras por estudio. Gráfico izquierdo: los 20 estudios con más obras. Gráfico derecho: cuántas obras hacen los estudios en su mayoría.

La Figura 4 muestra una enorme diferencia entre estudios. Unos pocos “gigantes” (como Toei, J.C.Staff, Sunrise) hacen cientos de series, pero la gran mayoría de los estudios han hecho apenas 1 o 2. Aquí es donde el modelo bayesiano brilla: no tratará igual el promedio de un estudio con 2 series que el de uno con 200, sino que usará la información general para estabilizar las notas de los estudios pequeños.

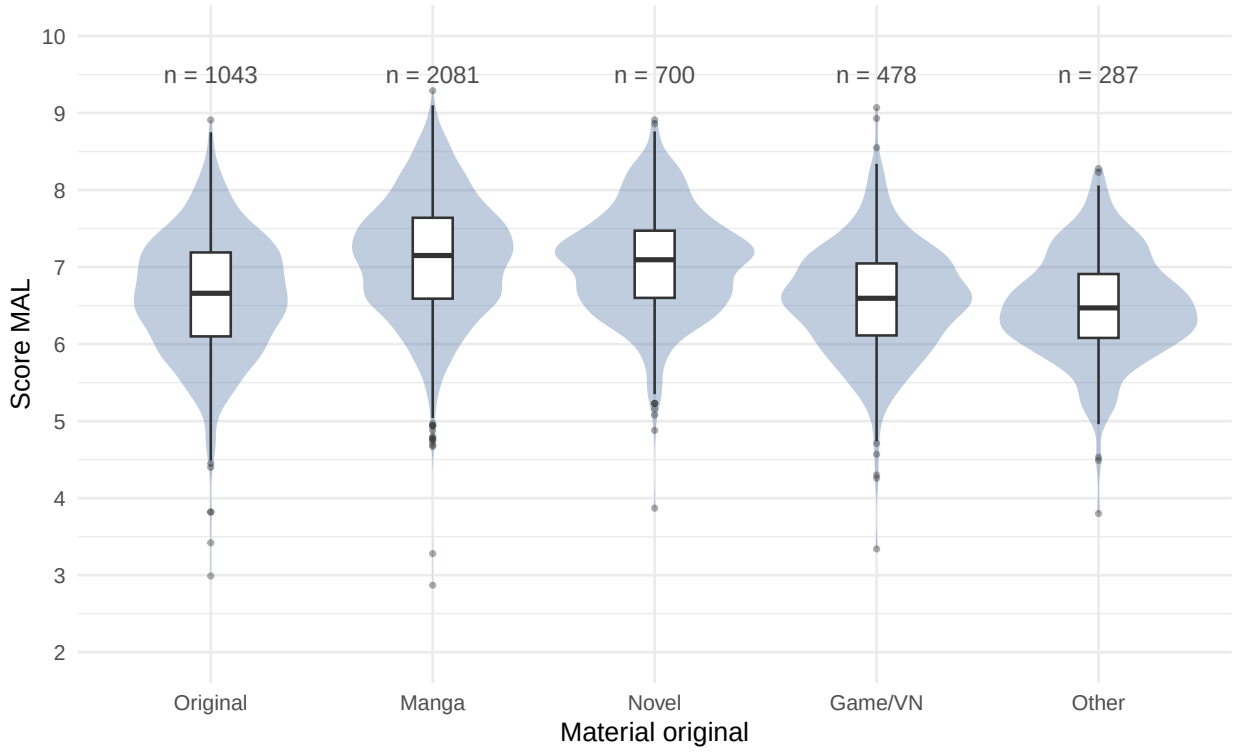

Figura 5: Distribución de notas según la procedencia de la historia (Manga, Novela, etc.).

La Figura 5 muestra que el material de origen afecta un poco a la nota. Las adaptaciones de mangas y novelas suelen ir un poquito mejor que las series 100 % originales. Sin embargo, la diferencia no es muy grande, lo que nos confirma que será muy útil ver cuánto de la nota final depende del material y cuánto depende del estudio que lo anima.

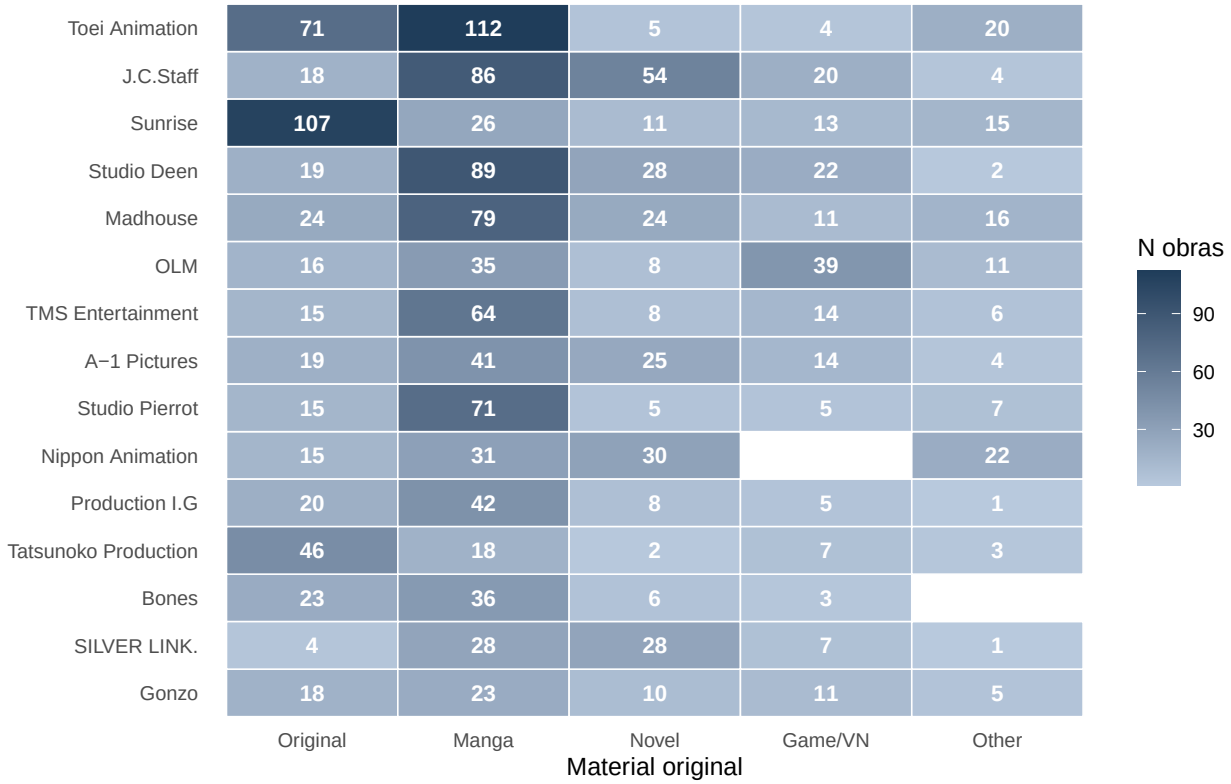

Figura 6: Frecuencia de obras por combinación Estudio × Material original (top 15 estudios). Las celdas vacías corresponden a combinaciones sin observaciones.

La Figura 6 cuantifica la dispersión empírica del cruce Estudio × Material original sobre los 15 estudios más productivos. La estructura revela patrones claros: algunos estudios muestran una clara orientación hacia un tipo de material (Sunrise y Tatsunoko Production producen mayoritariamente obras Originales, mientras que Toei Animation, J.C.Staff y Studio Pierrot se inclinan fuertemente hacia adaptaciones de Manga), otros como Madhouse o Studio Deen muestran un portafolio más diverso a lo largo de varias categorías. Igualmente importante es la gran cantidad de celdas con frecuencia muy baja, particularmente en las categorías Novel y Game/VN: muchas combinaciones Estudio × Source están escasamente representadas (varias con menos de 5 obras), e incluso aparecen combinaciones sin observaciones, lo que reafirma la dificultad de obtener estimaciones puntuales confiables para cada celda y refuerza el caso para un modelo que combine información a través de la estructura jerárquica.

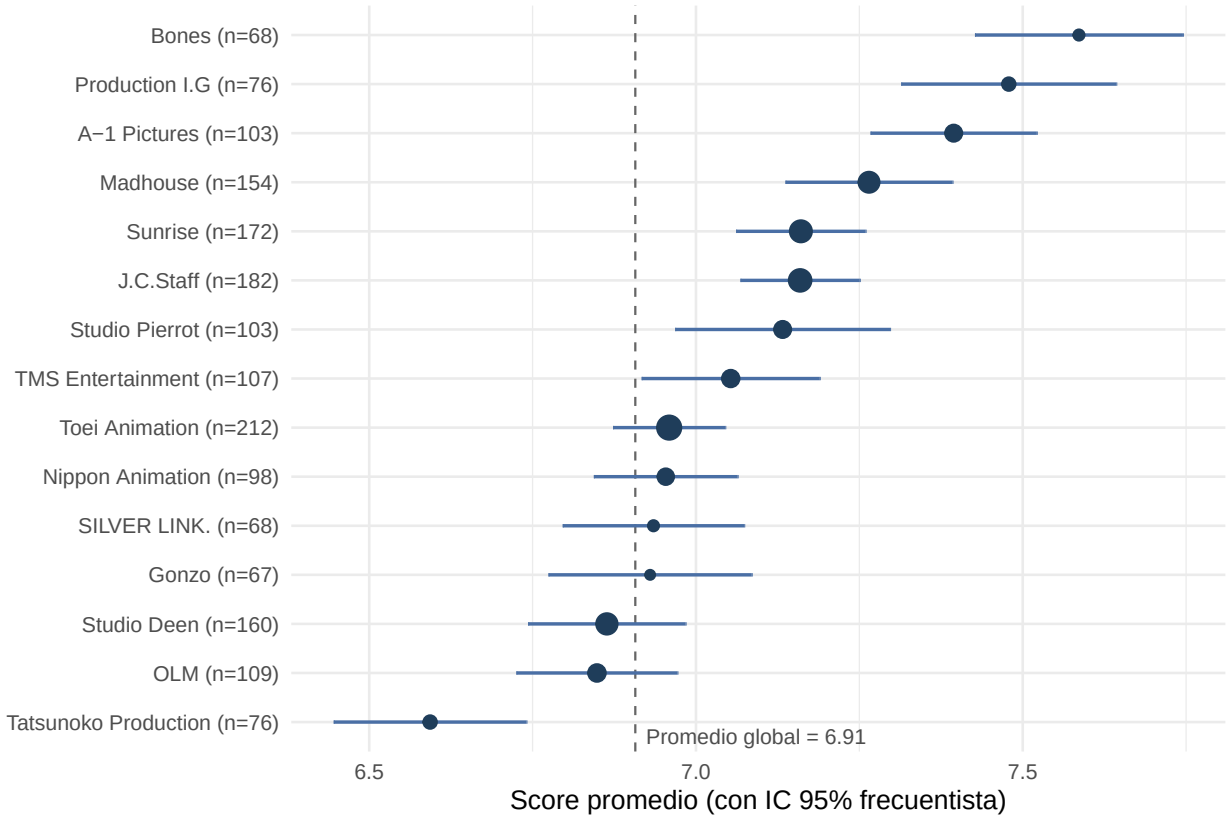

Figura 7: Score promedio por estudio (top 15 por número de obras), con intervalo de confianza frecuentista al 95 % basado en el error estándar de la media. La línea vertical discontinua marca el promedio global. El número entre paréntesis indica el tamaño de muestra.

La Figura 7 nos da un resumen de este problema. Cada punto representa la nota promedio de los 15 estudios con más obras, con su margen de error (las barras horizontales). Notamos dos cosas clave: primero, sí hay diferencias entre estudios (algunos están sistemáticamente por encima del promedio, como Bones o Madhouse, y otros por debajo como Tatsunoko). Segundo, los estudios con pocas obras tienen barras de error muy grandes. Aquí solo mostramos el "top 15"; si agregamos a los más de 200 estudios que han hecho menos de 5 series, esas medias serían totalmente inestables. Por eso necesitamos el modelo bayesiano, que puede agrupar la información y entregar estimaciones más sensatas.

4.3. Lado del consumo: géneros y fidelización

Tabla 3: Distribución de la tasa de favoritos en las series analizadas.

Estadística	Valor
Mínimo	0.000 %
Percentil 25	0.182 %
Mediana	0.340 %
Media	0.522 %

Estadística	Valor
Percentil 75	0.603 %
Percentil 90	1.105 %
Percentil 99	3.149 %
Máximo	9.430 %
Animes con tasa = 0	59
Animes con tasa > 1 %	520
Animes con tasa > 5 %	8

La Tabla 3 nos muestra algo vital: la tasa típica de fidelidad es muy, muy baja. La mitad de las series logran retener apenas alrededor de un 0.34 % de favoritos, y muchas de ellas tienen directamente cero favoritos. Esto significa que debemos usar modelos que toleren estas cifras tan infladas cerca del 0.

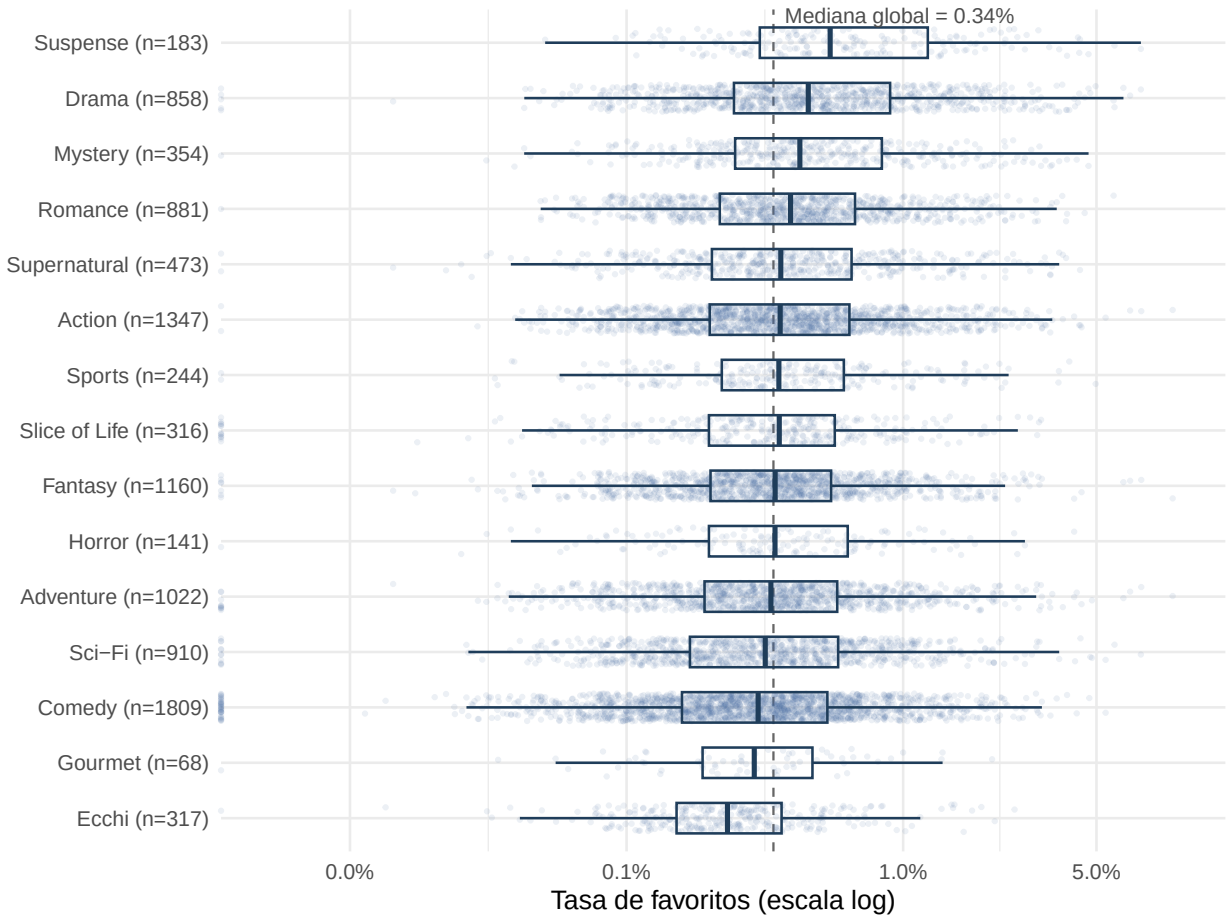

Figura 8: Comparación de la tasa de favoritismo entre los distintos géneros.

La Figura 8 nos dice que el género sí influye en cuán fiel se vuelve la audiencia. Géneros más de "nicho" o con tramas pesadas (como Suspenso, Misterio, Drama o Sci-Fi) logran una fidelidad mucho más alta que los enfocados al consumo rápido (como Comedia o Ecchi). Pero, dentro de cada género también hay mucha variación: un anime de Comedia aún puede volver muy fiel a su audiencia si está

bien hecho. Puesto que un anime suele tener mezclados muchos géneros (ej. Acción + Aventura), manejaremos estas etiquetas múltiples en nuestro modelo.

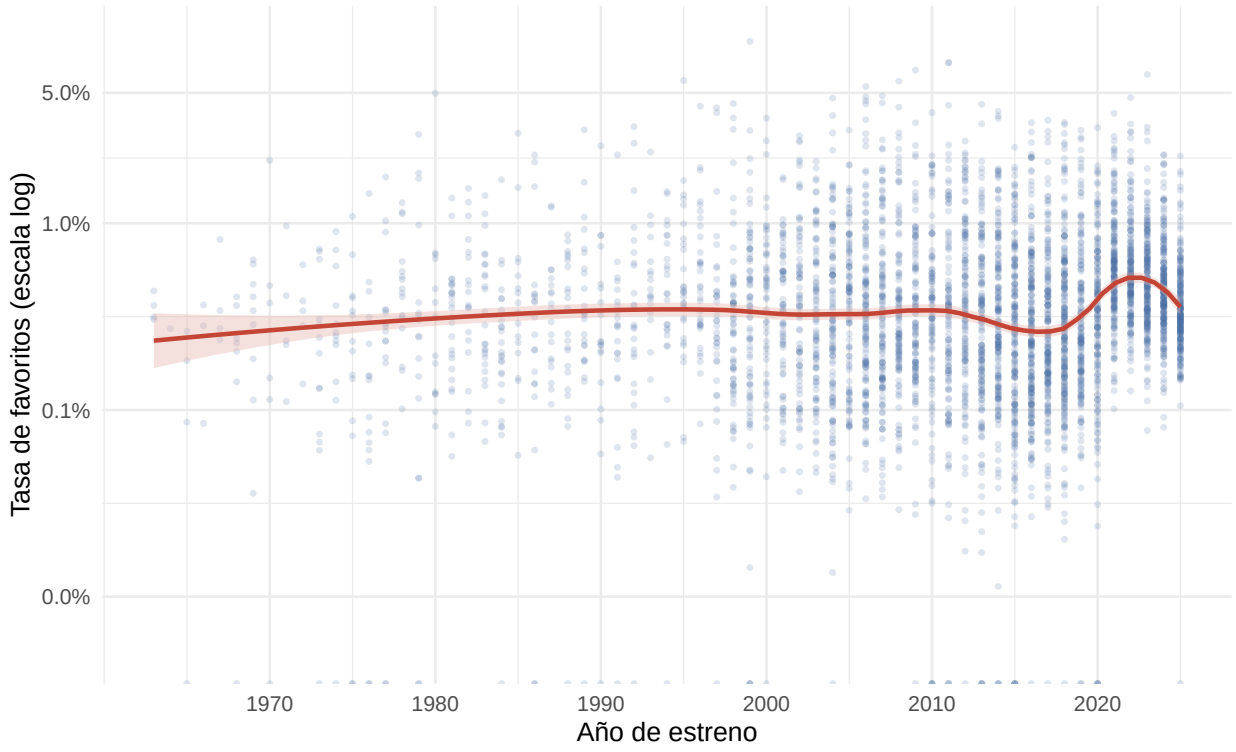

Figura 9: Tasa de favoritos a lo largo de los años.

La Figura 9 presenta un aspecto interesante a considerar: inicialmente se creía que los animes más nuevos tendrían tasas de favoritos más bajas, por tener menos tiempo en emisión. Pero la realidad es que la tasa general se ha mantenido súper estable a lo largo de las décadas, cerca del 0.3 %. Aun así, mantendremos el "Año" en el análisis para controlar posibles efectos en ciertas eras o en ciertos géneros de moda, como el "Isekai" reciente.

4.4. Comparación cruzada: ¿calidad y fidelización son lo mismo?

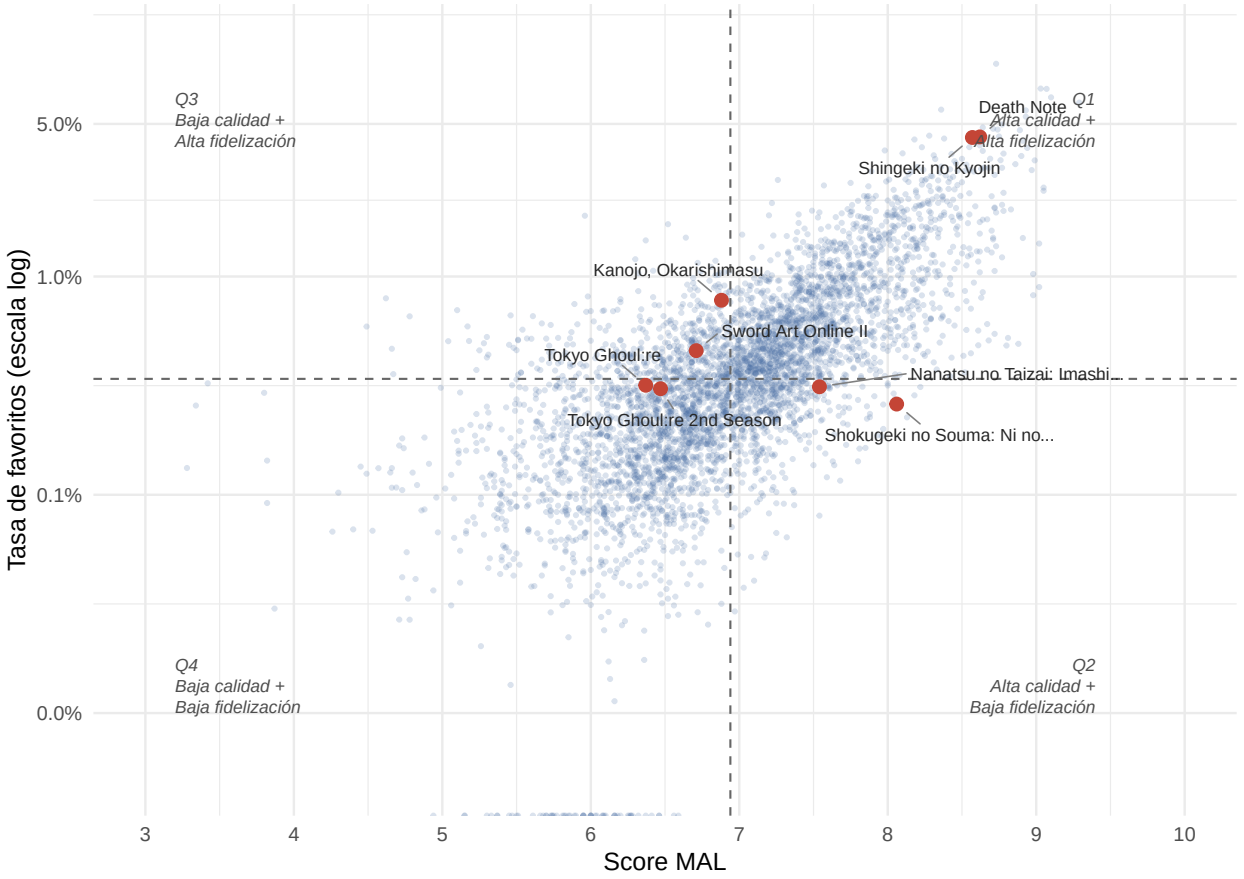

Figura 10: Relación entre Score MAL (eje x) y tasa de favoritos (eje y, escala log) para cada anime del subconjunto de la Pregunta 2. Las líneas discontinuas marcan las medianas globales y definen cuatro cuadrantes. Los puntos rojos identifican animes representativos seleccionados por su popularidad (Members) dentro de cada cuadrante.

La Figura 10 resume la gran duda de nuestro proyecto: ¿la nota y el favoritismo miden exactamente lo mismo? La respuesta es no. Sí están relacionadas (las series con buena nota suelen tener más fans), pero hay muchísimas excepciones.

Al dividir el gráfico en cuatro zonas con las medianas, vemos que casi un 22 % de los animes (unas 1.000 series) rompen la regla. Por ejemplo, en rojo marcamos casos famosos: **Shingeki no Kyojin** tiene notas altísimas y muchísimos fans; **Shokugeki no Souma** tiene buena nota pero pocos lo marcan como favorito (quizás por ser una secuela). Por el contrario, series como **Kanojo, Okarishimasu** no tienen las mejores notas, pero su comunidad es increíblemente fiel.

Esto justifica que necesitemos dos modelos distintos. Si la nota y la fidelidad fueran lo mismo, con un solo modelo bastaría. Como son cosas distintas, nuestros dos modelos nos ayudarán a entender qué mueve a cada una.

5. Próximos pasos

Para el informe final, armaremos paso a paso los modelos bayesianos de ambas preguntas.

Para la **Pregunta 1** usaremos un modelo jerárquico asumiendo que las notas (Score) se distribuyen de manera "Normal" o campana de Gauss (como vimos en la Figura 1). Este modelo suavizará las notas de los estudios que han hecho pocos animes, moviéndolas un poco hacia el promedio global para no sacar conclusiones apresuradas de un estudio con una sola obra exitosa. Controlaremos los resultados considerando si es un anime original, un manga adaptado, etc.

Para la **Pregunta 2** armaremos un modelo de proporciones para entender la fidelidad (Favoritos sobre Miembros). Como hay valores súper bajos y muchos ceros, el modelo tiene que estar preparado para manejar estas excepciones matemáticas. Incluiremos los géneros como grupos con variables de control sobre el año de estreno.

En ambos casos, haremos chequeos de rutina para validar que los modelos bayesianos corran sin problemas de matemáticas por detrás (chequeando convergencia) y revisaremos que predigan cosas que tengan sentido con la realidad de los datos. Al final, compararemos los resultados de ambos para ver si descubrimos estudios o géneros que sean reyes de la "buena nota" pero fracasen en "fidelidad", o viceversa.

6. Requisitos de Software y Librerías

Para compilar y ejecutar este documento Quarto (`propuesta.qmd`), es necesario tener instalado lo siguiente:

- **R y RStudio:** (o un visor de entorno compatible) para ejecutar el código.
- **Quarto:** Para compilar el documento en PDF y manejar el formato.

Librerías de R utilizadas: - `tidyverse` (para manipulación general y gráficos `ggplot2`) - `knitr` (para formato de tablas) - `scales` (para etiquetado en ejes de gráficos) - `patchwork` (para juntar gráficos) - `kableExtra` (para formato avanzado de tablas PDF) - `ggrepel` (para evitar superposiciones en las etiquetas de texto del último gráfico) - `stringr` y `forcats` (usadas como parte de `tidyverse`)

Referencias

Apriansyah, Syahrul. 2025. *MyAnimeList 2025: Comprehensive Anime Dataset*. Conjunto de datos en línea; Kaggle. https://www.kaggle.com/datasets/syahrulapriansyah2/myanimelist-2025.

Association of Japanese Animations (AJA). 2024--2025. *Anime Industry Report*. Reportes anuales sobre la industria de la animación japonesa. https://aja.gr.jp/english/japan-anime-data.

MyAnimeList LLC. 2025. *MyAnimeList: Base de datos y comunidad de anime y manga*. https://myanimelist.net.